

دانشگاه تهران، دانشکده مهندسی برق و کامپیوتر آمار و احتمال مهندسی

تمرین پنجم _ توابعی از متغیرهای تصادفی، امید ریاضی شرطی

طراح: امیرمهدی انصاریپور

سوپروایزر: سروش مسفروش مشهد

تاریخ تحویل: ۵ دی ۱۴۰۲

۱. چگالی احتمال مشترک

تابع چگالی احتمال مشترک متغیرهای تصادفی X و Y بصورت زیر است:

$$f_{X,Y}(x,y) = \frac{1}{2 \sigma^{\gamma}} e^{-\frac{x^{\gamma} + y^{\gamma}}{2 \sigma^{\gamma}}}$$

 $(W> ext{-})$ همچنین برای متغیرهای تصادفی Z و W داریم

$$\begin{cases} Z = \sqrt{X^{\mathsf{Y}} + Y^{\mathsf{Y}}} \\ W = XY \end{cases}$$

 $(f_{ZW}(z,w))$: تابع چگالی احتمال مشترک Z و W را بیابید

(نوشتن فرم بسته رابطه آخر اجباری نیست و در صورت درست بودن راه حل نمره کامل داده میشود)

پاسخ:

مىدانيم:

$$y_{\mathsf{Y},\mathsf{Y}} = \pm \sqrt{\frac{z^{\mathsf{Y}} - \sqrt{z^{\mathsf{Y}} - \mathsf{Y}w^{\mathsf{Y}}}}{\mathsf{Y}}}$$

$$X^{\mathsf{Y}} = \frac{W^{\mathsf{Y}}}{Y^{\mathsf{Y}}}$$

$$\longrightarrow x_{\mathsf{Y},\mathsf{Y}} = \pm \frac{|w|}{|y_{\mathsf{Y},\mathsf{Y}}|} = \pm \frac{w}{\sqrt{\frac{z^{\mathsf{Y}} + \sqrt{z^{\mathsf{Y}} - \mathsf{Y}w^{\mathsf{Y}}}}{\mathsf{Y}}}}$$

$$\longrightarrow x_{\mathsf{Y},\mathsf{Y}} = \pm \frac{|w|}{|y_{\mathsf{Y},\mathsf{Y}}|} = \pm \frac{w}{\sqrt{\frac{z^{\mathsf{Y}} - \sqrt{z^{\mathsf{Y}} - \mathsf{Y}w^{\mathsf{Y}}}}{\mathsf{Y}}}}$$

برای J(x,y) هم داریم:

$$J(x,y) = \det \begin{bmatrix} \frac{\partial Z}{\partial x} & \frac{\partial Z}{\partial y} \\ \frac{\partial W}{\partial x} & \frac{\partial W}{\partial y} \end{bmatrix} = \det \begin{bmatrix} \frac{x}{\sqrt{x^{\mathsf{Y}} + y^{\mathsf{Y}}}} & \frac{y}{\sqrt{x^{\mathsf{Y}} + y^{\mathsf{Y}}}} \\ y & x \end{bmatrix} = \frac{x^{\mathsf{Y}} - y^{\mathsf{Y}}}{\sqrt{x^{\mathsf{Y}} + y^{\mathsf{Y}}}}$$

با جایگذاری داریم:

$$f_{ZW}(z,w) = (\frac{f_{XY}(x_{\mathsf{1}},y_{\mathsf{1}})}{|J(x_{\mathsf{1}},y_{\mathsf{1}})|} + \frac{f_{XY}(x_{\mathsf{1}},y_{\mathsf{1}})}{|J(x_{\mathsf{1}},y_{\mathsf{1}})|} + \frac{f_{XY}(x_{\mathsf{1}},y_{\mathsf{1}})}{|J(x_{\mathsf{1}},y_{\mathsf{1}})|} + \frac{f_{XY}(x_{\mathsf{1}},y_{\mathsf{1}})}{|J(x_{\mathsf{1}},y_{\mathsf{1}})|})u(z)$$

(u(z) بزرگتر از صفر است. (دلیل Z

$$=(\frac{\frac{1}{\sigma^{\mathsf{T}}}e^{-\frac{z^{\mathsf{T}}}{\mathsf{T}\sigma^{\mathsf{T}}}}}{\frac{\mathsf{F}w^{\mathsf{T}}}{z(z^{\mathsf{T}}+\sqrt{z^{\mathsf{T}}-\mathsf{T}w^{\mathsf{T}}})}-z}+\frac{\frac{1}{\sigma^{\mathsf{T}}}e^{-\frac{z^{\mathsf{T}}}{\mathsf{T}\sigma^{\mathsf{T}}}}}{\frac{\mathsf{F}w^{\mathsf{T}}}{z(z^{\mathsf{T}}-\sqrt{z^{\mathsf{T}}-\mathsf{T}w^{\mathsf{T}}})}-z})u(z)$$

(نوشتن فرم بسته آخر اجباری نیست و در صورت درست بودن راه حل نمره کامل داده می شود)

۲۵ نمره

۲. واریانس شرطی و کوواریانس متغیر تصادفی توام

تابع چگالی احتمال متغیرهای تصادفی X و Y به صورت زیر است. مطلوب است محاسبه:

$$f(x, y) = \begin{cases} Axy & \cdot \le x \le y \le 1 \\ \cdot & \text{o.w.} \end{cases}$$

(نمره)
$$Var(Y|X=\frac{1}{r})$$
 (نمره) الف) $Cov(\cdot \wedge X, X+Y-1)$ نمره)

پاسخ:

الف)

ابتدا $f_{X|X}(y|x)$ و $f_{X}(x)$ را می یابیم:

$$\begin{split} f_X(x) &= \int_x^{\ \backprime} \mathsf{A} xy \, dy = \frac{\mathsf{A} x (\, \backprime - x^{\, \backprime})}{\, \backprime} \ \ (\, \backprime < x < \, \backprime) \\ f_{Y|X}(y|x) &= \frac{f_{X,Y}(x,y)}{f_X(x)} = \frac{xy}{\, \backprime x (\, \backprime - x^{\, \backprime})} = \frac{y}{\, \backprime (\, \backprime - x^{\, \backprime})} \ \ (\, \backprime \leq x \leq y \leq \, \backprime) \\ &: \land E(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\, \backprime}{\, \backprime}) \, e(Y^{\, \backprime} | X = \frac{\,$$

$$E(Y^{\mathsf{Y}}|X = \frac{\mathsf{Y}}{\mathsf{Y}}) = \int_{\frac{\mathsf{Y}}{\mathsf{Y}}}^{\mathsf{Y}} y^{\mathsf{Y}} \cdot f(Y|X = \frac{\mathsf{Y}}{\mathsf{Y}}) \, dy = \frac{\mathsf{Y}}{\mathsf{Y}} \int_{\frac{\mathsf{Y}}{\mathsf{Y}}}^{\mathsf{Y}} y^{\mathsf{Y}} \, dy = \frac{\mathsf{D}}{\mathsf{Y}}$$

 $Var(A) = E(A^{\mathsf{Y}}) - E(A)^{\mathsf{Y}}:$ میدانیم برای هر متغیر تصادفی مانند

$$\longrightarrow Var(Y|X=\frac{1}{r})=E(Y^{\mathsf{Y}}|X=\frac{1}{r})-\left[E(Y|X=\frac{1}{r})\right]^{\mathsf{Y}}=\frac{\Delta}{\mathsf{VY}}-(\frac{\mathsf{Y}^{\mathsf{Y}}}{\mathsf{Y}^{\mathsf{Y}}})^{\mathsf{Y}}\sim \mathsf{V}^{\mathsf{Y}}$$

ر)

با توجه به خواص Cov:

$$Cov(X,X) = Var(X)$$

$$Cov(aX,Y) = aCov(X,Y)$$

$$Cov(X,a) = \cdot (a \text{ is a constant})$$

$$\begin{split} &\longrightarrow Cov(\:\raisebox{1pt}{$\raisebox{1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{$\raisebox$1pt}{\raisebox$1pt}{\raisebox1pt}{\raisebox1pt}{\raisebox1pt}{\raisebox1pt}{\raisebox1pt}{\raisebox1pt}{\raisebox1pt}{\raisebox1pt}{\raisebox$1pt}{\raisebox$1pt}{\raisebox*1pt}{\raisebox1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1pt}{\raisebox*1p}{\raisebox*1p}{\raisebox*1pt}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}{\raisebox*1p}$$

برای محاسبه Var(X) داریم:

$$\begin{split} E(X) &= \int_{x=\cdot}^{\backprime} \int_{y=x}^{\backprime} x. f(x,y) \, dy dx = \int_{x=\cdot}^{\backprime} \int_{y=x}^{\backprime} \mathsf{A} x^{\mathsf{T}} y \, dy dx = \int_{x=\cdot}^{\backprime} (\mathsf{F} x^{\mathsf{T}} y^{\mathsf{T}} \Big|_{y=x}^{\backprime}) \, dx \\ &= \mathsf{F} \int_{\cdot}^{\backprime} (x^{\mathsf{T}} - x^{\mathsf{F}}) \, dx = \frac{\mathsf{A}}{\mathsf{I} \, \mathsf{D}} \end{split}$$

$$\begin{split} E(X^{\mathsf{Y}}) &= \int_{x=*}^{\mathsf{Y}} \int_{y=x}^{\mathsf{Y}} x^{\mathsf{Y}} . f(x,y) \, dy dx = \int_{x=*}^{\mathsf{Y}} \int_{y=x}^{\mathsf{Y}} \mathsf{A} x^{\mathsf{Y}} y \, dy dx = \int_{x=*}^{\mathsf{Y}} (\mathsf{Y} x^{\mathsf{Y}} y^{\mathsf{Y}} \Big|_{y=x}^{\mathsf{Y}}) \, dx \\ &= \mathsf{Y} \int_{*}^{\mathsf{Y}} (x^{\mathsf{Y}} - x^{\mathsf{D}}) \, dx = \frac{\mathsf{Y}}{\mathsf{Y}} \end{split}$$

$$\longrightarrow Var(X) = E(X^{\mathsf{T}}) - (E(X))^{\mathsf{T}} = \frac{\mathsf{T}}{\mathsf{T}\mathsf{T}\mathsf{D}}$$

برای محاسبه Var(Y) داریم:

$$E(Y) = \int_{y=.}^{\backprime} \int_{x=.}^{y} y.f(x,y) \, dx dy = \int_{y=.}^{\backprime} \int_{x=.}^{y} \mathsf{A} x y^{\mathsf{Y}} \, dx dy = \int_{x=.}^{\backprime} (\mathsf{Y} x^{\mathsf{Y}} y^{\mathsf{Y}} \Big|_{x=.}^{y}) \, dy = \int_{.}^{\backprime} \mathsf{Y} y^{\mathsf{Y}} \, d$$

$$\begin{split} E(Y^{\mathsf{Y}}) &= \int_{y=.}^{\mathsf{Y}} \int_{x=.}^{y} y^{\mathsf{Y}} . f(x,y) \, dx dy = \int_{y=.}^{\mathsf{Y}} \int_{x=.}^{y} \mathsf{A} x y^{\mathsf{Y}} \, dx dy = \int_{x=.}^{\mathsf{Y}} (\mathsf{Y} x^{\mathsf{Y}} y^{\mathsf{Y}} \Big|_{x=.}^{y}) \, dy = \\ &= \int_{.}^{\mathsf{Y}} \mathsf{Y} y^{\mathsf{Q}} \, dy = \frac{\mathsf{Y}}{\mathsf{Y}} \end{split}$$

$$\longrightarrow Var(Y) = E(Y^{\mathsf{T}}) - (E(Y))^{\mathsf{T}} = \frac{\mathsf{T}}{\mathsf{V}\Delta}$$

برای محاسبه Cov(X,Y) داریم:

$$\begin{split} E(XY) &= \int_{x=.}^{`} \int_{y=x}^{`} xy.f(x,y) \, dy dx = \int_{x=.}^{`} \int_{y=x}^{`} \wedge x^{\mathsf{r}} y^{\mathsf{r}} \, dy dx = \int_{x=.}^{`} \left(\frac{\wedge}{\mathsf{r}} x^{\mathsf{r}} y^{\mathsf{r}} \Big|_{y=x}^{`}\right) dx \\ &= \frac{\wedge}{\mathsf{r}} \int_{.}^{`} x^{\mathsf{r}} (\mathsf{I} - x^{\mathsf{r}}) \, dx = \frac{\mathsf{r}}{\mathsf{q}} \end{split}$$

$$\longrightarrow Cov(X,Y) = E(XY) - E(X)E(Y) = \frac{\mathbf{f}}{\mathbf{q}} - \frac{\mathbf{h}}{\mathbf{10}} \frac{\mathbf{f}}{\mathbf{0}} = \frac{\mathbf{f}}{\mathbf{770}}$$

نهایتا داریم:

$$Cov(\cdot \Delta X, X + Y - \Upsilon) = \cdot \Delta Var(X) + \cdot \Delta Cov(X, Y) = \frac{\Delta \Delta \cdot \Upsilon}{\Delta \cdot \Upsilon}$$

۳. توزیع انباشته ۲۰ نمره

متغیرهای تصادفی مستقل از هم X و Y با توزیع نمایی (بترتیب با پارامترهای λ و μ) را در نظر بگیرید:

$$X \sim \lambda e^{-\lambda x} u(x)$$

$$Y \sim \mu e^{-\mu y} u(y)$$

الف) تابع توزیع انباشته $S = X + Y \; (\text{CDF or } F_S(s))$ را بیابید. (۱۰ نمره)

(ب نمره) تابع توزیع انباشته $R = rac{X}{X+Y} ext{ (CDF or } F_R(r))$ را بیابید.

پاسخ:

پاسخ الف)

$$F_S(s) = P(S \le s) = P(X + Y \le s) = \int \int_{x+y \le s} f_X(x) f_Y(y) \, dx dy \stackrel{X \perp \!\!\! \perp Y}{=}$$

$$\int_{x \le s-y} f_X(x) \, dx \int_{-\infty}^{\infty} f_Y(y) \, dy = \int_{-\infty}^{\infty} F_X(s-y) f_Y(y) \, dy$$
 $f_Y(y) = \mu e^{-\mu y} u(y) \, \&\& \, F_X(x) = (\mathsf{1} - e^{-\lambda x}) u(x) \longrightarrow$ $y \ge \mathsf{1} \& s - y \ge \mathsf{1} \longrightarrow s \ge y : \mathsf{1}$ بدیهی است که $f_Y(y) = \mu e^{-\mu y} u(y) \, \&\& \, F_X(x) = \mathsf{1} \longrightarrow s \ge y : \mathsf{1}$ بدیهی است که $f_Y(y) = \mu e^{-\mu y} u(y) \, \&\& \, F_X(x) = \mathsf{1} \longrightarrow s \ge y : \mathsf{1}$

 $F_S(s) = \int_{\cdot}^{s} (1 - e^{-\lambda(s-y)}) \mu e^{-\mu y} dy = 1 - e^{-\mu s} - (\frac{e^{-\mu s} - e^{-\lambda s}}{\lambda - \mu})$

پاسخ ب)

$$F_{R}(r) = F_{\frac{X}{X+Y}}(r) = P(\frac{X}{X+Y} \le r) = \int \int_{\frac{x}{x+y} \le r} f_{X}(x) f_{Y}(y) \ dxdy \stackrel{X \coprod Y}{=} Y$$

$$\int_{x \le \frac{r}{1-r}y} f_{X}(x) \ dx \int_{-\infty}^{\infty} f_{Y}(y) \ dy = \int_{-\infty}^{\infty} F_{X}(\frac{r}{1-r}y) f_{Y}(y) \ dy =$$

$$\int_{\cdot}^{\infty} (1 - e^{-\lambda(\frac{r}{1-r})y}) \mu e^{-\mu y} \ dy = 1 - (\frac{\mu(1-r)}{r\lambda + (1-r)\mu}) (e^{-s(\frac{r\lambda}{1-r} + \mu)} - 1)$$

۴. قانون احتمال كل

 λ متغیر تصادفی N بیانگر تعداد کل مشتری هایی است که در یک روز وارد مغازه میشوند. این متغیر دارای توزیع پواسون با پارامتر λ است. هر مشتری با احتمال μ از این مغازه کالا می خرد (و بدیهی است که با احتمال μ نمی خرد.) متغیر تصادفی λ را تعداد مشتری هایی در نظر میگیریم که در همان روز کالایی نخریده اند. با نوشتن توزیع احتمال مشترک λ و λ را تعداد مشتری هایی در نظر میگیریم که در همان روز کالایی نخریده اند. با نوشتن توزیع احتمال مشترک λ و λ را تعداد که:

الف)
$$X$$
 و Y از هم مستقلند. (۱۰ نمره)

(مره)
$$P_X(x), P_Y(y)$$
 را بیابید. $P_X(x), P_Y(y)$

(راهنمایی: از قضیه احتمال کل کمک بگیرید)

پاسخ:

پاسخ الف)

فرض کنید تعداد مشتریانی که کالا خریده اند i و آنهایی که نخریده اند j باشد. داریم:

$$P_{XY}(X=i,Y=j|N=i+j) = Bionomial(i+j,p)$$

$$P_N(N=n) = Poisson(\lambda)$$

حال طبق قانون احتمال كل داريم:

$$P_{XY}(X = i, Y = j) = P_{XY}(X = i, Y = j | N = i + j).P_N(N = i + j) =$$

$$\frac{(i+j)!}{i!\ j!}p^i(\mathsf{I}-p)^j\frac{e^{-\lambda}\lambda^{i+j}}{(i+j)!}=(e^{-\lambda p}\frac{(\lambda p)^i}{i!})\times(e^{-\lambda(\mathsf{I}-p)}\frac{(\lambda(\mathsf{I}-p))^j}{j!})$$

$$= P_X(X=i).P_Y(Y=j)$$

از آنجا که این معادله برای تمامی مقادیر j و i بزرگتر از صفر برقرار است میتوان بطور کلی گفت:

$$P_{XY}(x,y) = P_X(x)P_Y(y)$$

در نتیجه X و Y مستقلند.

پاسخ ب)

همانطور که در بخش قبل بدست آوردیم:

$$P_X(x) = e^{-\lambda p} \frac{(\lambda p)^x}{x!} \quad P_Y(y) = e^{-\lambda(1-p)} \frac{(\lambda(1-p))^y}{y!}$$

 $X \sim Poisson(\lambda, p) \ Y \sim Poisson(\lambda, 1-p)$ بعبارت دیگر:

۵. مستقل و یکنواخت!

دو متغیر تصادفی مستقل U_1 و U_1 را در نظر بگیرید که هر دو توزیع یکنواخت پیوسته U_1 دارند. الف) $P(U_1|U_1>U_1)$ و $P(U_1|U_1>U_1)$ را بیابید. (۱۰ نمره) $E(U_1|U_1>U_1)$ و $E(U_1|U_1>U_1)$ را بیابید. (۱۰ نمره)

پاسخ:

پاسخ الف) از آنجا که دو متغیر مستقلند: (x) مقدار دلخواهی است)

$$f_{U_1,U_{\Upsilon}}(u_1,u_{\Upsilon})=f(u_1).f(u_{\Upsilon})=rac{1}{\Upsilon}$$

$$P(U_{\mathbf{1}} \leq x | U_{\mathbf{1}} > U_{\mathbf{T}}) = \frac{P(U_{\mathbf{1}} \leq x, U_{\mathbf{1}} > U_{\mathbf{T}})}{P(U_{\mathbf{1}} > U_{\mathbf{T}})} = \frac{\int_{\cdot}^{x} \int_{\cdot}^{u_{\mathbf{1}}} \frac{1}{\mathbf{F}} \, du_{\mathbf{T}} du_{\mathbf{1}}}{\frac{1}{\mathbf{F}}} = \frac{x^{\mathbf{T}}}{\mathbf{F}}$$

$$P(U_{\mathbf{Y}} \leq x | U_{\mathbf{Y}} > U_{\mathbf{Y}}) = \frac{P(U_{\mathbf{Y}} \leq x, U_{\mathbf{Y}} > U_{\mathbf{Y}})}{P(U_{\mathbf{Y}} > U_{\mathbf{Y}})} = \frac{\int_{\cdot}^{x} \int_{u_{\mathbf{Y}}}^{\mathbf{Y}} \frac{1}{\mathbf{Y}} \, du_{\mathbf{Y}} du_{\mathbf{Y}}}{\frac{1}{\mathbf{Y}}} = x - \frac{x^{\mathbf{Y}}}{\mathbf{Y}}$$

 $(P(U_1=x)=\cdot$ ردقت شود از آنجا که متغیرها پیوسته هستند نمیتوان از تساوی استفاده کرد. بعبارت دیگر پیوسته هستند نمیتوان از تساوی استفاده کرد. بعبارت دیگر پیوسته پیاسخ ب)

$$E(U_{\mathsf{I}}|U_{\mathsf{I}} > U_{\mathsf{T}}) = \int_{\mathsf{I}}^{\mathsf{T}} u_{\mathsf{I}} f(u_{\mathsf{I}}|u_{\mathsf{I}} > u_{\mathsf{T}}) du_{\mathsf{I}}$$

:برای یافتن $f(u_1|u_1>u_1)$ داریم

$$f(u_1|u_1 > u_1) = \frac{d}{dx}P(U_1 \le x|U_1 > U_1) = \frac{x}{y}$$

$$\longrightarrow E(U_1|U_1 > U_1) = \int_{\cdot}^{y} u_1 \frac{u_1}{y} du_1 = \frac{y}{y}$$

$$E(U_1|U_1 > U_1) = \int_{\cdot}^{y} u_1 (1 - \frac{u_1}{y}) du_1 = \frac{y}{y}$$

۶. رگرسیون خطی (امتیازی)

دو متغیر تصادفی X و Y را در مسئله رگرسیون خطی زیر در نظر بگیرید:

$$Y = aX + b$$

۵) الف) با استفاده از روش MSE مقدار بهینه پارامتر های a و b را بیابید. پارامتر a چه رابطه ای با ضریب همبستگی a مقدار بهینه پارامتر های a و b را بیابید. پارامتر a چه رابطه ای با ضریب همبستگی a مقدار بهینه پارامتر های a دارد؟ (۵)

(۵ نمره) طبق رابطه بدست آمده در بخش الف مقدار a و b را با توجه نمونه های داده شده بیابید.

پاسخ:

پاسخ الف) طبق روش squared mean داريم:

$$\begin{split} a^*, b^* &= \min \, E[(Y - (aX + b))^{\mathsf{Y}}] \\ \frac{dE[(Y - (aX + b))^{\mathsf{Y}}]}{da} &= E[\mathsf{Y}(Y - aX - b)(-X)] = \mathsf{Y}(Y - aX - b)(-X) \\ &\longrightarrow aE[X^{\mathsf{Y}}] + bE[X] = E[XY] \quad (\mathsf{Y}(Y - aX - b)(-X)) \end{split}$$

معادله دوم را با مشتق گرفتن نسبت به b بدست می آوریم:

$$\frac{dE[(Y - (aX + b))^{\Upsilon}]}{db} = E[\Upsilon(Y - aX - b)(-\Upsilon)] = \Upsilon$$

$$\longrightarrow b = E[Y] - aE[X] \quad (\Upsilon)$$

با استفاده از این دو معادله داریم:

$$aE[X^\intercal] + (E[Y] - aE[X])E[X] = E[XY] \longrightarrow a(E[X^\intercal] - E^\intercal[X]) = E[XY] - E[X]E[Y]$$
 با توجبه به تعریف $Var(X)$ و $Var(X)$

$$a = \frac{Cov(X,Y)}{Var(X)} \times \frac{Var(Y)}{Var(Y)} = \frac{\rho(X,Y)\sigma_y}{\sigma_x}$$

پاسخ ب)

$$E[X] = \frac{(\mathbf{Y}\mathbf{1} + \mathbf{1}\mathbf{1} + \mathbf{1}\mathbf{9} + \mathbf{0})}{\mathbf{Y}} = \mathbf{1}\mathbf{Y}/\mathbf{Y}\mathbf{0} & \&\& \ E[X^{\mathbf{Y}}] = \mathbf{Y}\mathbf{Y}\mathbf{1}/\mathbf{Y}\mathbf{0} \longrightarrow$$

$$Var[X] = \mathbf{Y}\mathbf{Y}/\mathbf{Y}\mathbf{0} & \&\& \ \sigma_x = \mathbf{9}/\mathbf{0}\mathbf{Y}$$

$$E[Y] = \frac{(\mathbf{A}\mathbf{1} + \mathbf{Y}\mathbf{1} + \mathbf{0}\mathbf{0} + \mathbf{Y}\mathbf{1})}{\mathbf{Y}} = \mathbf{0}\mathbf{1}/\mathbf{Y}\mathbf{0} & \&\& \ E[Y^{\mathbf{Y}}] = \mathbf{Y}\mathbf{9}\mathbf{1}/\mathbf{Y}\mathbf{0} \longrightarrow$$

$$Var[Y] = \mathbf{Y}\mathbf{0}\mathbf{Y}/\mathbf{9}\mathbf{0} & \&\& \ \sigma_y = \mathbf{1}\mathbf{0}/\mathbf{0}\mathbf{Y}$$

$$E[XY] = \frac{\mathbf{Y}\mathbf{Y}\mathbf{0}}{\mathbf{Y}} = \mathbf{1}\mathbf{1}\mathbf{0}/\mathbf{0}\mathbf{0} \longrightarrow Cov(X,Y) = \mathbf{1}\mathbf{1}\mathbf{Y}/\mathbf{0}\mathbf{Y}\mathbf{0}$$

$$\longrightarrow a = \mathbf{Y}/\mathbf{9}\mathbf{Y} & \&\& \ b = \mathbf{1}\mathbf{Y}/\mathbf{0}\mathbf{Y}$$